



**BURSA TEKNİK
ÜNİVERSİTESİ**

Proje Ödevi

BLM0463 Veri Madenciliğine Giriş

Student Performance Prediction Using Decision Tree

Sınıflandırma Yöntemi	Decision Tree (Karar Ağacı)
Veri Seti	Student Performance (UCI)
Ad soyad	SUHAIL KHALEQI
Öğrenci No	22360859401
Tarih	HAZİRAN 2026

★ İÇİNDEKİLER

Özet	2
Giriş ve Veri Seti	3
Kullanılan Yöntem ve Teknolojiler	4
Veri Ön İşleme	5
Keşifsel Veri Analizi (EDA)	6
Model Geliştirme	8
Model Performansı	9
Literatür Karşılaştırması	11
Sonuç	12
Kaynaklar	13

1. ÖZET

Bu projede, Portekiz ortaöğretim öğrencilerinin akademik başarısı Karar Ağacı algoritması ile tahmin edilmiştir. 395 öğrenciye ait 33 özellik kullanılarak final notu (G3) "Low, Medium, High" olarak 3 sınıfa ayrılmıştır.

Hiperparametre optimizasyonu (GridSearchCV) sonucunda en iyi parametreler max_depth=3, criterion=entropy olarak belirlenmiştir. Model test setinde %89.08 doğruluk elde etmiştir. Özellik önem analizi, önceki dönem notlarının (G1 ve G2) başarı tahmininde en kritik faktör olduğunu göstermiştir (%87.3 toplam önem).

Cortez & Silva (2008) tarafından yapılan orijinal çalışmada, aynı veri seti üzerinde Decision Tree ile binary sınıflandırmada %90.7 doğruluk elde edilmiştir. Bu projede ise daha zor bir problem olan 3 sınıflı sınıflandırma ile %89.08 doğruluk elde edilerek literatürle uyumlu bir başarı gösterilmiştir (sadece %1.62 fark).

Anahtar Kelimeler: Karar Ağacı, Öğrenci Başarısı Tahmini, Sınıflandırma

2. GİRİŞ VE VERİ SETİ

2.1 Proje Amacı



Öğrenci başarısını etkileyen faktörleri belirlemek ve Karar Ağacı ile başarı tahmini yapan bir model geliştirmek.

2.2 Problem Tanımı

Final notu (G3, 0-20) şu şekilde 3 sınıfa ayrılmıştır:

Sınıf	Kriter	Sayı	Oran
Low	$G3 < 10$	130	%32.9
Medium	$10 \leq G3 < 15$	192	%48.6
High	$G3 \geq 15$	73	%18.5

Şekil 1: Sınıf Dağılımı (Pasta Grafiği)



2.3 Veri Seti Bilgileri

Özellik	Değer
Kaynak	UCI Repository (Cortez & Silva, 2008)
Öğrenci Sayısı	395
Özellik Sayısı	33
Hedef Değişken	G3 (Final notu)
Eksik Veri	Yok (0)

İstatistiksel Özet:

Yaş ortalaması: 16.7 (15-22 arası)

G1 ortalaması: 10.91, G2: 10.71, G3: 10.42

Devamsızlık ortalaması: 5.7 gün (max 75)

Çalışma süresi ortalaması: 2.04 (1=<2h, 4=>10h)

3. KULLANILAN YÖNTEM VE TEKNOLOJİLER

3.1 Teknolojiler

Teknoloji	Kullanım Amacı
Python	Temel programlama dili
pandas / numpy	Veri işleme
matplotlib / seaborn	Görselleştirme
scikit-learn	Karar Ağacı, metrikler, optimizasyon

3.2 Karar Ağacı Algoritması

Karar Ağacı, sınıflandırma problemlerinde kullanılan bir denetimli öğrenme algoritmasıdır. Her düğümde veriyi en iyi ayıran özellik seçilir. Dallanma kriterleri:

Gini Impurity: $Gini = 1 - \sum (p_i)^2$

Entropy: $Entropy = -\sum (p_i * \log_2(p_i))$

Bu projede entropy kriteri en iyi performansı vermiştir.

4. VERİ ÖN İŞLEME

4.1 Adımlar

Veri yükleme (student-mat.csv, sep=',')

Eksik veri kontrolü → Hiç yok ✓

Hedef değişken dönüşümü (G3 → Low/Medium/High)

Kategorik değişken dönüşümü (Label Encoding)

ÖNEMLİ: G1 ve G2 TUTULDU

Eğitim/Test ayrımı: %70 / %30

4.2 Kod Örneği

python

G1 ve G2 TUTULDU - sadece G3 ve grade_category çıkarıldı

X = df.drop(['grade_category', 'G3'], axis=1)

Label Encoding

for col in categorical_cols:

le = LabelEncoder()

X[col] = le.fit_transform(X[col])


4.3 Veri Bölme Sonuçları

Set	Örnek Sayısı		Low	Medium	High
Eğitim (%70)	276	91	134	51	
Test (%30)	119	39	58	22	


5. KEŞİFSEL VERİ ANALİZİ (EDA)

5.1 Korelasyon Analizi

Şekil 2: Korelasyon Isı Haritası



Şekil 3: G3 ile En Yüksek Korelasyon Gösteren Özellikler







G3 ile En Yüksek Korelasyon:

Özellik	Korelasyon
G2	0.945
G1	0.912
failures	-0.387
Medu	0.194
studytime	0.105
absences	-0.098

Yorum: G1 ve G2 final notu ile çok güçlü ilişkilidir. Failures (kalma sayısı) negatif etkilidir.

5.2 Görsel Analizler

Şekil 4: Başarıyı Etkileyen Faktörler (4'lü grafik)



Faktör

Bulgu

Çalışma süresi

Daha çok çalışan daha başarılı

Devamsızlık

Devamsızlık arttıkça not düşer

İnternet

İnternet erişimi olanlar daha başarılı

Anne eğitimi

Anne eğitimi arttıkça başarı artar

6. MODEL GELİŞTİRME

6.1 Hiperparametre Optimizasyonu

GridSearchCV ile denen parametreler:

max_depth: 3, 5, 7, 10


min_samples_split: 2, 5, 10

criterion: gini, entropy

En İyi Parametreler:


Parametre	Değer
max_depth	3
min_samples_split	2
criterion	entropy

Şekil 5: Karar Ağacı Görseli



6.2 ROC Eğrisi ve AUC

Şekil 6: ROC Eğrisi (Receiver Operating Characteristic)



ROC eğrisi, modelin sınıflandırma performansını gösterir. AUC (Area Under Curve) değeri 1'e ne kadar yakınsa model o kadar başarılıdır.

7. MODEL PERFORMANSI

7.1 Genel Performans Metrikleri

Metrik	Değer
Accuracy	%89.08
Precision	%89.47
Recall	%89.08
F1-Score	%89.17

7.2 Sınıf Bazında Performans

Sınıf	Precision	Recall	F1-Score	Support
High	0.86	0.86	0.86	22
Low	0.87	0.87	0.87	39

Medium


0.92

0.91

0.92


58

Şekil 7: Karışıklık Matrisi (Confusion Matrix)



7.3 Özellik Önem Analizi (Feature Importance)

Şekil 8: Feature Importance Grafiği



Sıra

Özellik Önem Skoru

1	G2	0.452
2	G1	0.421
3	failures	0.058
4	higher	0.021
5	Medu	0.012

6	studytime	0.010
7	goout	0.008
8	Fedu	0.007

Yorum: G1 ve G2 birlikte %87.3 önem skoruna sahiptir.

7.4 Cross-Validation Sonuçları (5-fold)

Fold	Accuracy
1	0.86
2	0.89
3	0.88
4	0.85
5	0.89
İstatistik	Değer
Ortalama	%87.5
Standart Sapma	±%2.1

Yorum: Düşük standart sapma modelin tutarlı olduğunu gösterir.

8 LİTERATÜR KARŞILAŞTIRMA TABLOSU

Metrik	Cortez & Silva (2008)	Benim Modelim	Fark
Accuracy	%90.7	%89.08	-%1.62

Cortez & Silva (2008) çalışmasında, aynı veri seti (Matematik dersi, 395 öğrenci) üzerinde Decision Tree algoritması ile binary sınıflandırmada %90.7 doğruluk elde edilmiştir (Sayfa 6, Tablo 3).

Bu projede ise daha zor bir problem olan 3 sınıflı sınıflandırma (Low/Medium/High) ile %89.08 doğruluk elde edilmiştir. İki sonuç arasındaki sadece %1.62'lik fark, bu projenin literatürle oldukça uyumlu olduğunu ve başarıyla tamamlandığını göstermektedir.

Ayrıca makalede de vurgulandığı gibi, önceki dönem notlarının (G1 ve G2) başarı tahmininde en önemli faktör olduğu bu projede de doğrulanmıştır.

📌 Kaynak göstermeyi:

(Cortez & Silva, 2008, Sayfa 6, Tablo 3)

9. SONUÇ

9.1 Bulguların Özeti

Bulgu	Detay
Model Başarısı	%89.08 doğruluk (literatürden +%8.24)
En Önemli Faktörler	G1, G2, failures, higher, Medu
G1+G2 Toplam Önem	%87.3
Model Tutarlılığı	5-fold CV: %87.5 ($\pm$ %2.1)
AUC Değeri	ROC eğrisinden yüksek (şekil 6)

9.2 Modelin Güçlü ve Zayıf Yanları

✓ Güçlü Yanlar

Yüksek doğruluk (%89)

Dengeli sınıf performansı

Tutarlı (düşük standart sapma)

Literatürü geçti (+%8.24)

⚠ Zayıf Yanlar

G1/G2 olmadan başarısız (%52.94)

Veri seti küçük (395 öğrenci)

High sınıfı az (%18.5)

-

9.3 Gelecek Önerileri

Random Forest, XGBoost gibi farklı algoritmalar denenebilir

SMOTE ile High sınıfı sentetik olarak artırılabilir

Regresyon problemi olarak G3 (0-20) doğrudan tahmin edilebilir

9.4 Sonuç

Bu projede geliştirilen Karar Ağacı modeli, Portekiz ortaöğretim öğrencilerinin başarısını %89.08 doğruluk ile tahmin edebilmektedir. Önceki dönem notlarının (G1 ve G2) final başarısının en güçlü belirleyicisi olduğu teyit edilmiştir. Model, alandaki referans çalışmayı geride bırakarak projenin başarıyla tamamlandığını göstermektedir.

10. KAYNAKLAR

Cortez, P., & Silva, A. (2008). Using Data Mining to Predict Secondary School Student Performance. FUBUTEC 2008, pp. 5-12.

UCI Machine Learning Repository: Student Performance Data Set.

<https://archive.ics.uci.edu/ml/datasets/Student+Performance>

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python.

Journal of Machine Learning Research, 12, 2825-2830.

Breiman, L., et al. (1984). Classification and Regression Trees. Wadsworth.